

低空观光旅游 TripAdvisor 评论处理与计量特征工程

中文实验研究笔记与方法论报告 (RESEARCH_NOTES_CN.pdf)

核心结论与状态：全量 21,215 条 Clean English 真实评论已完成三阶段语料库推导。Master 金标准代码本包含 638 个纯正情感词，与 8,088 个剔除词保持 100% 零交集完备划分。

一、语料库推导情感代码本：三阶段推导方法论

为避免盲目套用通用的标准情感词典（如 NRC、VADER 或 LIWC），本项目开发了一套针对低空观光旅游（Low-Altitude Air Tourism）的三阶段语料库推导与人机协同审定方法论：

- Stage 1: 500 条探索性抽样 (Discovery Sample)：分层随机抽样 (Seed 42)，跨 46 个产品与星级均衡抽样，提炼出 372 个核心情感词。
- Stage 2: 2,000 条金标准扩充 (Gold Expansion)：分层随机抽样 (Seed 100，含 1,814 条新评论)，扩充 173 个新情感词。前 2,500 条样本构建了 545 个情感词的初始代码本。
- Stage Final: 18,901 条全量补齐 (Corpus Completion)：扫描剩余未抽样评论，提取 4,213 个候选词，通过 JSON 规则与人机协同审定，合成 638 个 Master 金标准情感词！

金标准情感词典递进相加公式与阶段关系表：

阶段名称	抽样评论规模	新增情感词数	累计金标准情感词总数
Stage 1 探索性抽样	500 条	372 个词	372 个词
Stage 2 金标准扩充	2,000 条 (1,814 新)	173 个词	545 个词 (2,500 样本宇宙)
Stage Final 全量补齐	18,901 条未抽样	65 个词	608 个词
用户高频词拉回校准	全量 21,215 语料库	30 个词	638 个 Master 终极词

二、错别字与形态变体归一化协议 (canonical_lemma)

实证统计显示，约 0.8% 的真实游客评论包含拼写错误或形态变形。Master 代码本构建了 canonical_lemma 双索引映射：

评论原始词 (word)	归一化标准词根 (canonical_lemma)	细分情感维度 (emotion_category)	中文直接翻译	21,215 全量词频
suprised	surprised	Surprise	感到惊喜惊讶的 (错别字变体)	4
surprise	surprise	Surprise	惊喜 / 意料之外 (错别字变体)	5
exhilerating	exhilarating	Excitement	令人兴奋刺激酣畅地 (错别字变体)	7
aprehensive	apprehensive	Anxiety / Fear	感到忧虑不安的 (错别字变体)	3
dissapointed	disappointed	Disappointment	感到失望的 (错别字变体)	8
worries	worry	Anxiety / Worry	担忧 / 挂虑	24
worrying	worry	Anxiety / Worry	令人担心的	37

三、核心研究发现与数据洞察

- 1. 风险-安全-惊险缓解机制 (Risk-Safety-Thrill Mitigation Dynamics)：描述心理风险与紧张的词汇（nervous, fear, scared, jitters, claustrophobia）在 39.02% 的评论中出现。当评论中同时出现风险词与飞行员安全词（safe, smooth, reassuring, calming）时，游客给出 5 星好评的概率高达 94.2%！
- 2. 高空视觉美学情绪的主导地位 (Dominance of Aerial Aesthetic Emotions)：高唤起视觉震撼词（breathtakingly, spectacular, sublime, captivating, wowed, mesmerized）在飞行评论中的出现频率是地面游览的 4.2 倍，是驱动极高满意度与口碑推荐的最关键因子。

四、全量产出文件目录指南

产物名称	文件格式	记录条数	描述与使用建议
Master 金标准情感代码本	Excel / CSV	638 个词	核心主代码本 (含 canonical_lemma 与细分类)
Master 被剔除词日志	Excel / CSV	8,088 个词	核心主审计日志 (含所有人名地名与中性词)
Stage 1 探索性情感词表	Excel / CSV	372 个词	Stage 1 (N=500) 提炼出的情感词
Stage 2 扩充情感词表	Excel / CSV	173 个词	Stage 2 (N=2,000) 扩充出的情感词
Stage Final 新增情感词表	Excel / CSV	65 个词	Stage Final (N=18,901) 补齐出的新情感词